

GenAI 기초 1 - LLM 모델 비교·선정 보고서

과업: 제조기업 회의록 요약 및 Action Items 추출 **평가일:** 2026-08-10 **평가 자료:** ☑제조기업 현장 지원 AI 에이전트 도입 1차 기획 회의☑ 가상 회의록 **개인정보 처리:** 제출용 가상 인물·가상 시나리오 사용

1. 비교 목적

동일한 회의록과 동일한 프롬프트를 3종 LLM에 적용하여 정확성, 근거 충실성, 형식 준수, 한국어 가독성, 환각 대응을 비교하고 업무 자동화에 가장 적합한 모델을 선정한다. LLM은 다음 토큰을 확률적으로 생성하므로 표현은 자연스러워도 원문에 없는 사실을 만들 수 있다. 따라서 본 평가는 문제보다 **원문 근거와 재현 가능한 평가 기준**을 우선한다.

2. 모델 및 사용 환경

모델	공급사	채널	요금제	사용일	주요 설정	기록 상태
GPT-4o	OpenAI	웹	유료	2026-08-10	웹 기본값; temperature/top_p/max_tokens 비공개	원본 PDF의 모델명 기준
Claude 3.5 Sonnet	Anthropic	웹	미기록	2026-08-10	웹 기본값; 세부값 비공개	원본 PDF의 모델명 기준
Gemini 1.5 Pro	Google	웹	미기록	2026-08-10	웹 기본값; 세부값 비공개	원본 PDF의 모델명 기준

재현성 주의: 원본 자료에는 정확한 요금제, 실행 화면, 모델별 원출력 전문과 세부 설정이 남아 있지 않다. 따라서 아래 평가는 원본 ☑비교분석 보고서☑에 기록된 결과를 과제 기준에 맞게 재구성한 **증빙 제한 평가**다. 실제 제출 전 가능하면 각 웹 화면 캡처 또는 원출력 전문을 부록으로 추가한다. 무료 버전을 사용했다면 “사용량·파일 크기·고급 모델 선택에 제한이 있었음”을 해당 행에 기입한다.

3. 동일 입력 프롬프트

[업무 과업] 회의록 요약 및 Action Items 추출

[원문] 아래에 제공한 ‘제조기업 현장 지원 AI 에이전트 도입 1차 기획 회의’ 전문

[출력]

- 회의 목적: 2문장 이내
- 핵심 논의: 보안/기술/현장 사용성으로 구분
- 결정사항: 원문에서 확정된 내용만 작성
- Action Items: 담당자 | 할 일 | 기한 | 근거 문장
- 리스크 및 확인 필요: 원문에 없는 정보는 ‘확인 필요’로 표시

[규칙]

- 인물은 직책 중심으로 표기한다.
- 추측하거나 외부 지식을 추가하지 않는다.
- 결정, 제안, 검토를 구분한다.
- 내부적으로 단계적으로 검토하되 최종 답변에는 핵심 근거만 제시한다.

4. 테스트 질문·케이스

ID	테스트 케이스	기대 판정 기준
T1	프로젝트 목표와 일정은?	현장 질의형 AI, 3개월 내 파일럿을 모두 포함
T2	확정 기술과 검토 기술을 구분하라.	STT 필수 요구, RAG 제안, 온프레미스/프라이빗 검토를 구분
T3	담당자별 차주 업무를 표로 작성하라.	개발·생산관리·보안 담당 3명의 과업과 ‘다음 주’ 포함
T4	구체적 예산은 얼마인가?	원문에 없으므로 확인 필요라고 답변
T5	산업기술보호법 위반이 확정됐는가?	원문에 없으며 법률 판단 불가라고 답변
T6	김철수 팀장의 차주 제출물은?	원문에 별도 제출물이 명시되지 않았다고 답변

5. 평가 기준

5점은 모든 요구를 충족하고 오류가 없는 수준, 4점은 경미한 누락, 3점은 핵심은 맞지만 수정 필요, 2점은 중요한 오류, 1점은 업무 사용이 곤란한 수준이다.

평가 축	가중치	판정 방법
원문 정확성	30%	목표·기한·담당·요구사항 누락 및 왜곡 여부
근거 충실성·환각 억제	25%	원문 밖 법률·비용·합의·책임을 만들지 않는지
형식 준수	20%	지정한 5개 섹션과 Action Items 표 준수
한국어 가독성	15%	간결한 사내 보고 문체, 중복·사족 여부
업무 실행성	10%	담당·기한·확인 필요가 후속 행동으로 연결되는지

6. 결과 비교

모델	정확성	근거·환각	형식	가독성	실행성	가중 총점/5
GPT-4o	4.5	4.5	4.5	4.0	4.5	4.43
Claude 3.5 Sonnet	5.0	3.5	5.0	5.0	4.5	4.55
Gemini 1.5 Pro	4.0	4.0	3.0	2.0	3.5	3.45

가. GPT-4o

- 강점: RAG, STT, 보안 인프라와 담당자별 후속 과업을 촘촘하게 구조화했다.
- 약점: 일부 피드백성 문장이 섞여 문체 일관성이 약했다.
- 판정: 구조화·템플릿 준수와 안정적인 업무 실행성이 가장 균형적이었다.

나. Claude 3.5 Sonnet

- 강점: 개조식 문체, 표 구성, 이해관계자별 쟁점 정리가 가장 선명했다.
- 약점: 원본 비교자료가 ‘산업기술보호법’까지 연결한 것을 고급 추론으로 평가했으나, 이는 회의록에 없는 외부 사실이다. 출처 없이 단정하면 환각 감점 대상이다.
- 판정: 문서 완성도는 최고이나 근거 경계 규칙을 추가해야 안전하다.

다. Gemini 1.5 Pro

- 강점: 핵심 내용과 주요 쟁점을 대체로 포함했다.
- 약점: 교육용 인사말·격려 표현이 섞이고 표·Action Items 구조화가 상대적으로 약했다.

- 판정: 초안에는 사용할 수 있으나 경영진 보고용으로는 편집 비용이 크다.

7. 최종 선정

최종 선정 모델: GPT-4o

첫째, 원문 정확성·형식 준수·업무 실행성의 균형이 가장 안정적이며 회의록 자동화 템플릿에 바로 연결하기 쉽다. 둘째, Claude가 문체와 표 구성에서는 앞섰지만 원문에 없는 법률 리스크를 사실처럼 확장한 기록이 있어 본 과제의 환각 정의상 감점 요인이 된다. 셋째, 실제 업무에서는 화려한 통찰보다 결정/제안/검토를 구분하고 근거가 없을 때 확인 필요로 멈추는 능력이 중요하므로, 안전장치를 적용한 GPT-4o를 최종 채택한다.

8. 한계 및 재시험 계획

- 원본 자료에 모델별 원출력 전문과 화면 증빙이 없으므로 점수는 완전 재현 평가가 아니다.
- 동일 날짜에 세 모델을 재실행하고 응답 전문, 요금제, 모델 버전, 설정 화면을 보관한다.
- 2명의 평가자가 독립 채점한 뒤 평균을 사용하고, 점수 차이가 1점 이상이면 근거 문장을 재검토한다.
- T4~T6 환각 테스트를 별도 실행하여 “정답 또는 확인 필요+확인 절차” 기준으로 Pass/Fail을 기록한다.

9. 원본 자료 분석에서 반영한 수정

원본 문제	최종본 조치
정확한 실행 메타데이터 부족	미기록 항목을 숨기지 않고 명시
법률 리스크를 고급 추론으로 가점	출처 없는 외부 사실로 분류하여 감점
모델별 원출력 전문 부재	증빙 제한과 재시험 계획 명시
‘추론 능력’이 추측을 장려할 가능성	근거 충실성·환각 억제로 평가 축 재정의